ADS401 EVALUATION METHODS AND STATISTICS

LibAI 对比评估实验

实施手册、任务材料与采访提纲

比较 LibAI、DeepSeek 与 ChatGPT 在固定文献检索和文献理解任务中的输出质量、响应时间、用户满意度与预期符合程度。

设计	参与者	任务
3×2 完全被试内	24-30 名 XJTLU 研究生	检索 + 理解

ADS401 Group J

Version 1.0 | 2026-11-08

用途：组内实施、Presentation 3 设计与补充材料

当前状态

本文件描述的是拟议实验，不是实验结果。当前已完成问卷阶段，有效样本 107 人；三种 AI 的任务实验尚未实施。

01 一页概览

本实验使用完全相同的两个任务和完全相同的输入，比较三种 AI 的输出。同一名参与者会使用全部三种系统，因此个人 AI 使用经验、学科背景和操作速度可以由参与者自身作为对照。

项目	最终决定
研究问题	在相同检索与阅读任务下，三种 AI 的答案质量、速度、满意度和预期符合度是否不同?
设计	3×2 完全被试内实验：AI 三个水平 × 任务两个水平
参与者	24-30 名 XJTLU 研究生，目标至少 24 份完整数据
任务一	固定 Prompt 检索三篇真实同行评审论文并核查来源
任务二	使用同一固定摘要，完成研究问题、方法、发现和限制总结
核心结果	任务成功、客观答案质量、time to useful answer、满意度、信任
次结果	心理努力、预期符合度、再次使用意愿、访谈主题
实验时长	约 60-75 分钟，其中任务约 30-40 分钟

为什么这样设计

- 问卷显示“查找、筛选相关文献”和“阅读、总结或解释文献”各有 61 人使用过，均为最高频任务。
- 用户最重视可核查来源和准确性；速度只被 6 人选为首要改进方向。
- 固定输入减少用户提示词能力差异，使系统间比较更可解释。
- 同一参与者体验全部系统，可降低个人差异，但需要平衡系统与任务顺序。
- 答案质量由研究者盲评，用户评价只承担主观体验部分。

展示口径

Presentation 3 应说明：“本次展示已完成问卷阶段的统计，任务实验为下一阶段方案。”不得将尚未收集的任务数据表述为实验结果。

02 研究问题、假设与变量

编号	研究问题
RQ1	在统一的文献检索请求下，三种 AI 的任务成功、答案质量和用户满意度是否存在差异?
RQ2	在统一的文献理解请求下，三种 AI 的总结准确性、完整性和满意度是否存在差异?
RQ3	AI 差异是否随任务类型变化，即是否存在 AI × 任务交互效应?
RQ4	再次使用意愿更受答案准确性、来源可核查性、响应时间还是心理努力影响?

预设假设

假设	内容
H1	三种 AI 在任务成功率、答案质量和用户满意度上存在显著差异。
H2	AI 类型的效果随任务类型变化，存在 AI × 任务交互效应。
H3	再次使用意愿与答案准确性和来源可核查性的关联强于与响应时间的关联。

变量结构

类型	变量	操作化
自变量 1	AI 类型	LibAI、DeepSeek、ChatGPT
自变量 2	任务类型	固定检索任务、固定理解任务
客观因变量	速度	首内容时间、time to useful answer、完整生成时间
客观因变量	质量	任务成功、正确文献数、准确性、完整性、来源真实性、幻觉数
主观因变量	体验	满意度、信心、预期符合、心理努力、信任、再次使用意愿
控制变量	输入与环境	同一 Prompt、摘要、设备、浏览器、网络、时限和模型版本

03 实验设计与顺序平衡

条件	文献检索	文献理解
LibAI	固定检索 Prompt	固定摘要与理解 Prompt
DeepSeek	固定检索 Prompt	固定摘要与理解 Prompt
ChatGPT	固定检索 Prompt	固定摘要与理解 Prompt
观察数	每名参与者 3 次	每名参与者 3 次

建议招募 30 人，目标获得至少 24 份完整数据。24 人时按六种 AI 顺序各分配 4 人，再在一个顺序组内平衡任务先后。

组别	AI 顺序	先做任务一的人数	先做任务二的人数
G1	LibAI → DeepSeek → ChatGPT	2	2
G2	LibAI → ChatGPT → DeepSeek	2	2
G3	DeepSeek → LibAI → ChatGPT	2	2
G4	DeepSeek → ChatGPT → LibAI	2	2
G5	ChatGPT → LibAI → DeepSeek	2	2
G6	ChatGPT → DeepSeek → LibAI	2	2

抽样要求

目标样本比例为约 40% LibAI 当前或曾经使用者、60% 未使用者。根据清洗后的问卷，前者 43 人、后者 64 人，因此实验不应全部招募 LibAI 积极用户。

参与者纳入标准

- 18 岁以上。
- 目前为 XJTLU 研究生。
- 平时需要完成文献检索、阅读或总结任务。
- 能够阅读中文学术材料和英文论文题名。
- 自愿参与，并签署知情同意书。

环境与设备控制

- 同一实验室、同一电脑、同一浏览器和同一网络。
- 关闭通知和无关标签页，固定浏览器缩放比例。
- 每次 trial 开启新对话，不使用记忆或跨会话上下文。
- 三个系统采用相同账号权限和默认语言设置。
- 记录模型名称、可见版本、测试日期和网络状态。
- 三个系统出现临时服务故障时，记录故障，不把故障时间算作用户表现。

04 任务一：固定文献检索

所有参与者向三个 AI 输入完全相同的检索请求。任务以任务清单为完成标准，不是以 AI 是否声称“完成”作为标准。

任务一统一输入 Prompt

请围绕“生成式人工智能在高校图书馆学术支持服务中的应用”这一主题，检索三篇2022年及以后发表在同行评审期刊上的论文。

每篇请列出：
1. 作者；
2. 发表年份；
3. 完整论文题名；
4. 期刊名称；
5. DOI；
6. 数据库或来源链接；
7. 用一句话说明该论文为什么符合本主题。

请优先提供可以直接打开和核查的来源。无法核实的论文或引用请明确标注，不要编造。

回答结束后，请说明你如何验证了至少一个DOI或来源链接。

实验员与用户规则

- Prompt 放在任务卡中供复制，所有人发送相同文字。
- 从点击发送开始计时，到用户点击“答案足够”结束。
- 用户可打开 AI 提供的 DOI 或来源链接核查，但不能另开普通搜索引擎寻找答案。
- 第一轮回答不完整时，最多使用一次统一补全 Prompt。
- 六分钟仍未完成，记录为任务未完成，不继续给研究者提示。
- 不提醒用户哪个答案更好，不帮助改写问题。

统一补全 Prompt（最多一次）

请只补充任务要求中尚未满足或表达不清的内容，并明确标出每一项的信息来源。不要重复已经正确的内容，不要编造无法核实的文献或引用。

任务一完成标准

检查项	完全成功的标准
论文数量	返回三篇论文
存在性	题名、作者、年份和 DOI 可对应到真实记录
发表条件	2022 年及以后，且属于同行评审期刊
主题	论文确实讨论生成式 AI 与高校图书馆学术支持服务
来源	至少一个 DOI 或链接可打开并支持结论
引用	无虚构文献、错误 DOI 或无依据引用

05 任务一后的评价

任务一结束后立即填写。所有题目采用 1-7 分，7 表示最积极的一端。同时记录一个用户自报的符合要求论文数量。

编号	问题	量表
T1-1	你对这个回答总体满意吗?	1 非常不满意 - 7 非常满意
T1-2	这个回答满足任务要求的程度如何?	1 完全没满足 - 7 完全满足
T1-3	返回的论文与该主题有多相关?	1 完全不相关 - 7 非常相关
T1-4	你对论文真实性和 DOI 正确性有多大信心?	1 非常低 - 7 非常高
T1-5	这些来源有多容易核查?	1 非常困难 - 7 非常容易
T1-6	实际表现与你使用前的预期相比如何?	1 远低于预期 - 7 远高于预期
T1-7	你愿意在真实作业或研究中使用这份回答吗?	1 非常不愿意 - 7 非常愿意
T1-8	你认为几篇论文符合全部要求?	0 / 1 / 2 / 3 / 无法判断

任务一的时间与行为记录

字段	记录方式	用途
首内容时间	发送至第一个可见回答内容	比较系统初始响应
time to useful answer	发送至用户点击“答案足够”	主速度指标
完整生成时间	发送至生成结束	辅助理解总等待成本
统一追问	是否使用，使用前后质量是否改善	衡量获得可用答案的额外操作
任务成功	0-3 篇真实且符合要求的论文	客观任务表现
来源核查	DOI 是否可打开、是否支持结论	评价证据可信度

为何仍需盲评

用户满意度不能代替客观答案质量。用户可能因为格式漂亮、答案较长或语气自信而给出高分，但论文可能不存在、DOI 错误或来源不支持结论。

06 任务二：固定文献理解

任务二使用研究团队提供的固定短摘要，避免不同用户的检索结果和论文难度影响理解任务。所有参与者使用同一摘要和同一问题。该摘要为标准化实验材料，其中的研究及数字为虚构示例，不作为真实文献引用。

任务二统一输入 Prompt

请只根据下面提供的摘要回答，不要添加摘要中没有的信息。

摘要：
本研究旨在检验嵌入可核查引用链接的生成式检索工具能否提升研究生的文献检索表现。研究采用随机实验，将76名研究生分配到AI检索组和传统数据库组，要求两组在30分钟内找到5篇符合主题与年份条件的论文。结果显示，AI组任务完成率为84.2%，传统数据库组为65.8%；AI组平均用时18.4分钟，传统组为24.1分钟。然而，AI组出现无法核实来源的比例为16.7%，传统组为5.3%。作者认为，AI工具可能提高检索速度，但必须配合来源核查。研究仅在一所大学开展，任务时间较短，结果可能无法推广到长期真实研究。

请按照以下结构回答：
1. 研究问题；
2. 研究设计与方法；
3. 样本；
4. 两项主要发现，并保留具体数字；
5. 两项研究限制；
6. 该研究最适合支持什么结论；
7. 该研究不能支持什么结论。

任务二标准答案要点

项目	标准答案
研究问题	嵌入可核查引用的生成式检索工具能否改善研究生检索表现
设计与方法	随机实验，AI 检索组与传统数据库组比较
样本	76 名研究生
主要发现 1	完成率 84.2% 对 65.8%；平均用时 18.4 分钟对 24.1 分钟
主要发现 2	无法核实来源比例 16.7% 对 5.3%
限制	仅一所大学、任务时间较短
可支持结论	该短期检索任务中 AI 可能提高速度和完成率，但仍需来源核查
不可支持结论	AI 在所有学科和长期真实研究中都更有效，或速度提升等于可靠性提升

07 任务二评价与系统整体评价

任务二后的即时问题

编号	问题	量表
T2-1	你对这个总结总体满意吗?	1 非常不满意 - 7 非常满意
T2-2	回答覆盖了任务要求七个部分的程度如何?	1 非常不完整 - 7 完全完整
T2-3	回答准确保留摘要中数字的程度如何?	1 多处错误 - 7 全部准确
T2-4	回答是否添加了摘要之外的信息?	1 添加很多 - 7 完全没有添加
T2-5	回答的结构是否清楚易懂?	1 非常不清楚 - 7 非常清楚
T2-6	实际表现与你使用前的预期相比如何?	1 远低于预期 - 7 远高于预期
T2-7	你愿意在学习中使用这个系统的总结能力吗?	1 非常不愿意 - 7 非常愿意

客观记录

- 是否识别研究问题。
- 是否识别研究设计、分组和样本量。
- 正确保留的数字数量。
- 正确识别的限制数量。
- 添加摘要之外信息的数量。
- 是否得出超出摘要证据范围的因果结论。

每完成一个 AI 后的整体问题

编号	问题（1-7 分）
S1	这个系统能够支持我完成文献任务。
S2	这个系统使用起来简单省力。
S3	等待时间可以接受。
S4	我信任这个系统给出的答案。
S5	我能方便地确认答案是否真实。
S6	我知道如何向它提出我需要的问题。
S7	我愿意在真实学习中再次使用它。
S8	我愿意向同学推荐它。
S9	我对这个系统总体满意。

08 完整实验流程

时间	步骤	实验员要做什么
-10 至 0 分钟	准备	准备设备、网络、三个 AI、任务卡、同意书和数据表
0-5 分钟	知情同意	照读研究说明，签署同意书，单独询问录屏同意
5-10 分钟	背景问卷	完成人口学、AI 经验、LibAI 经验和系统预期
10-13 分钟	培训	解释任务卡、计时和追问，进行无关短练习
13-43 分钟	六个 trial	按顺序完成三个 AI × 两类任务，任务后即时评分
中途	短暂休息	完成约三个 trial 后休息 3 分钟
43-50 分钟	系统排序	完成每系统整体评分、整体排序和使用意愿
50-60 分钟	访谈	根据知情同意进行 8-10 分钟半结构访谈
60-63 分钟	Debrief	解释研究目的，回答疑问，感谢参与者

实验员照读说明

Participant briefing

你将使用三种 AI 完成两类文献任务。

第一类是查找论文，第二类是阅读和总结一段摘要。每个任务都有固定问题，请不要自行修改主要问题。

我们评价的是系统，不是你的能力。所有回答都会匿名处理。

每个任务最多六分钟。你可以在认为答案已经足够时点击“任务完成”，也可以在无法完成任务时点击“无法完成”。

你可以打开 AI 提供的来源链接进行核查，但不要另外使用普通搜索引擎替代 AI 查找答案。

每个 trial 的计时规则

时间点	操作
T0	用户点击发送统一 Prompt
T1	第一个可见答案内容出现
T2	完整生成结束
T3	用户点击“答案足够”，记为主速度指标
T4	若使用统一补全 Prompt，记录为一次额外交互
6 分钟	仍未完成则停止，记录 timeout 和任务失败

09 实验后采访提纲

建议所有参与者完成最后排序和简短开放评论；选择 8-10 人进行 8-10 分钟半结构访谈。配额建议：4 名 LibAI 当前或曾经使用者、4 名未使用者，并包含不同学科和不同满意度水平。录音须取得单独同意。

Interview opening

开场：刚才你使用了三种 AI 完成两类文献任务。我想了解你实际如何判断答案是否可用，以及为什么作出这样的选择。这里没有正确或错误答案，也不是评价你的个人能力。

编号	主问题	追问
I1	请回忆刚才最顺利的一次使用经历。它为什么顺利?	哪个系统、哪类任务、你做了什么?
I2	请回忆一次让你不满意或不敢信任的经历。	当时发生了什么？你如何发现?
I3	在文献检索中，你主要根据什么判断结果好不好?	相关性、数量、DOI、来源、速度还是格式?
I4	你是否真的打开并核查了 AI 提供的来源?	什么情况下会核查，什么情况下不会?
I5	在文献理解中，你如何判断总结是否准确?	会检查数字、方法、限制还是逻辑?
I6	系统很快但来源不可靠，与系统较慢但答案可靠，你会怎样选择?	检索和理解任务的选择是否不同?
I7	三个系统中，哪个最不需要追问？哪个最需要额外核查?	举一个具体例子。
I8	检索任务和理解任务分别会选择哪个 AI？为什么?	选择依据是否相同?
I9	LibAI 最主要的优点和不足分别是什么?	与通用 AI 相比如何?
I10	LibAI 做到什么，才会让你主动选择它?	需要入口、来源、速度还是整合?
I11	只能优先改进一项时，你选择什么？为什么?	准确性、来源、覆盖、速度还是操作?
I12	我们是否遗漏了你觉得重要的问题?	请补充。

追问原则

- 询问具体事件和行为，不要求参与者猜测研究假设。
- 避免“你是不是觉得 LibAI 更差”这类引导问题。
- 用“当时发生了什么” “你依据什么判断”代替“你为什么不喜欢” 。
- 不要与参与者争论答案是否正确，客观正确性由研究者盲评。

10 答案评分与数据记录

由两名组员隐藏 AI 名称后独立评分。先评 pilot，统一评分锚点，再开始正式评分。评分者不应看到系统名称或用户满意度分数。

维度	0 分	2 分	4 分
正确性	核心内容错误	部分正确但有重要遗漏	正确且完整
相关性	未回答任务	部分相关	直接满足任务
完整性	缺少大部分要求	只完成部分清单	完成全部要求
来源可核查性	无来源或虚构	部分可核查	关键结论均有真实来源
清晰操作性	无法使用	需要大量整理	可直接据此完成任务

必须单独记录的答案错误

- 虚构论文数量。
- 错误 DOI 数量。
- 错误作者、年份或期刊数量。
- 无法打开的来源数量。
- 来源存在但不能支持答案结论的数量。
- 理解任务中添加摘要之外信息的数量。
- 超出摘要证据范围的因果结论。

建议的 trial-level 数据字段

字段	数据类型	说明
participant_id	文本	P001-P024 等匿名编号
ai_order	分类	六种轮换顺序之一
task_order	分类	检索优先或理解优先
ai	分类	LibAI / DeepSeek / ChatGPT
task_type	分类	search / comprehension
ttft_s	数值	首内容时间，秒
useful_s	数值	用户点击答案足够的时间，秒
completion_s	数值	完整生成时间，秒
followup_used	0/1	是否使用统一补全 Prompt
task_success	0/1	是否满足任务完成标准
quality_total	0-20	五个维度的总分
false_citations	整数	虚构或错误引用数量
satisfaction	1-7	总体满意度
trust	1-7	信任程度
expectation_match	1-7	实际与预期比较
reuse_intent	1-7	再次使用意愿

数据核对规则

- 每一行代表一名参与者使用一个 AI 完成一个任务，不将三种 AI 的结果混在同一行。
- 答案质量评分者只能看到匿名化的回答文本，不得看到 AI 名称和用户满意度。
- 任务超时不等同于空值：记录 timeout，并将该 trial 计为任务失败。
- 缺失主观评分保留为空，不能自动填 0；分析时报告缺失数量。
- 所有派生指标保留原始时间和原始评分，便于复核和重算。

Data-entry check

建议在正式数据收集前建立 trial-level 数据模板，并由两名组员用一条测试回答共同完成字段录入和评分，确认字段含义一致。

11 统计与定性分析方案

描述统计

指标	报告方式
响应时间	中位数、四分位距、最小值、最大值、timeout 次数
正确文献数量	每种 AI 的中位数和 0-3 分布
任务成功率	计数和比例
满意度、信任、预期	平均值、标准差和分布
答案质量	五维度总分、均值、标准差和评分者一致性

推断统计

- 连续评分先检查正态性和球形假设。
- 符合假设时使用两因素重复测量 ANOVA，检验 AI、任务及交互效应。
- 不符合假设时使用 Friedman 检验。
- AI 两两比较使用 Wilcoxon 符号秩检验，并用 Holm 或 Bonferroni 校正。
- 任务成功等二元结果可使用 Cochran’ s Q；样本允许时考虑混合效应模型。
- 答案质量评分报告 ICC 或同类评分者一致性指标。
- 效应量应随 p 值一起报告，不以 $p < .05$ 作为唯一结论。

预测用户再次使用意愿

建议模型

再次使用意愿 ~ 可用答案时间 + 任务成功 + 答案质量 + 来源可核查性 + 心理努力 + 是否使用过 LibAI

访谈分析

- 先完整转写并匿名化参与者编号。
- 采用 reflexive thematic analysis，不预设满意度一定由速度或准确性造成。
- 初始编码可以包括速度、准确性、来源核查、信任、提示负担、工作流和任务差异。
- 比较 LibAI 使用者与非使用者对同一事件的解释。
- 访谈只用于解释和扩展定量结果，不代替实际任务表现。

解释原则

response time 和 task success 是不同的结果。回答很快但错误，或回答正确但需要长时间核查，都不能简单称为“更方便”。分析时应分别报告，再讨论二者组合。

12 第三次 Presentation 的呈现方式

由于当前只有问卷数据，第三次 pre 应呈现问卷统计结果和实验方案，不得报告尚未收集的 AI 对比结果。这样既真实，也能清楚说明下一阶段研究计划。

幻灯片	标题	内容
1	问题来源	107 份有效问卷；LibAI 使用与未使用结构；研究目标
2	问卷阶段结果	主要任务、障碍和改进优先级；来源与准确性高于速度
3	研究问题	相同检索与理解任务下，三种 AI 的质量、速度和满意度差异
4	实验设计	3×2 完全被试内；六种 AI 顺序；任务顺序平衡
5	任务与测量	固定 Prompt、固定摘要、time to useful answer、客观评分
6	反思与下一步	pilot、伦理、限制、正式数据收集与分析计划

建议的结尾表述

Presentation 3 closing

> 本次展示的是问卷阶段的统计结果和下一阶段实验方案。三种 AI 的任务实验尚未完成，因此本次不报告假设性实验结果。下一步将通过 pilot 检验任务时限和材料，再按照平衡顺序的 3×2 被试内设计完成正式数据收集。

补充材料 ZIP 建议

- 清洗后的问卷数据和变量说明。
- 问卷统计输出与图表。
- 本实验实施手册。
- 任务卡、统一 Prompt 和统一摘要。
- 任务后、系统后评分表。
- 答案评分表和数据记录模板。
- 参与者告知书与同意书。
- 访谈提纲与匿名化说明。
- AI 使用声明和必要引用。

13 伦理、限制与实施清单

伦理要求

- 正式收集人类参与者数据前完成课程要求的伦理审查和导师确认。
- 提供独立的 Participant Information Sheet 和 Informed Consent Form。
- 录屏和录音分别征得同意，不因拒绝录制而排除参与者。
- 所有任务使用预设问题，不输入真实论文、研究数据或个人信息。
- 参与者数据使用匿名编号，保存位置与访问权限在告知书中说明。
- 实验后 debrief，明确研究对象是系统而非参与者能力。

主要限制

- 同一用户重复相同问题可能产生记忆和顺序效应，通过六种 AI 顺序和任务顺序平衡缓解。
- 固定 Prompt 提高控制，但降低自然使用的外部效度。
- LibAI 与通用 AI 的资源范围与产品定位不同，不能把数据库权限差异解释成模型能力。
- AI 模型和界面会变化，必须记录产品版本与测试日期。
- 24-30 人是课程项目的现实规模，但不足以对所有 XJTLU 研究生作总体推断。
- 用户满意度可能受到答案长度、排版和品牌预期影响，因此必须保留客观盲评。

实验前最终检查清单

状态	项目
□	LibAI、DeepSeek、ChatGPT 均能在实验设备上稳定访问
□	ChatGPT 不可用时的替换方案已在 pilot 前确定
□	任务一的候选正确论文与 DOI 已人工核实
□	任务二的标准答案已由两名组员核对
□	六种 AI 顺序和两种任务顺序已生成参与表
□	任务卡、Prompt、评分表和访谈提纲已定稿
□	告知书、同意书、录屏与录音同意已准备
□	数据表字段、匿名编号和保存位置已确定
□	已完成 3-5 人 pilot 并记录修改
□	评分者已完成一次共同评分校准
□	已准备 debrief 说明和 AI 使用声明

Final principle

实验材料的核心原则：所有参与者输入相同内容；研究者记录实际行为；用户评价体验；两名评分者盲评质量；任何结果都区分“快”与“正确”。

材料依据：ADS401 Coursework Sheet - Presentation v1.0；实验设计与统计分析课程材料；LibAI 使用体验与需求调查中文修订版；清洗后有效样本 107 人的问卷数据。